Guía Canónica de Bibliografía y Citas de Autoridad

Fundamentos y Arquitectura de Sistemas con Modelos System One (Jev AI)

Documento Anexo y Guía de Profundización Técnica para la Serie Formativa

---

Nota para el lector y estudiante:
Este documento compila de forma sistemática todas las referencias técnicas, libros canónicos de la biblioteca oficial de **O'Reilly Learning**, artículos de investigación fundacional y obras clásicas de economía y neurociencia citadas en los vídeos de la serie. Cada referencia incluye su contexto de aplicación y enlace directo para permitir una consulta rápida de las fuentes primarias.

1. Obras Técnicas Canónicas (Biblioteca O'Reilly Learning)

1.1. Arquitectura de Sistemas de IA, Patrones de Diseño y Agentes

- **AI Engineering**
  Autora: Chip Huyen · **Editorial:** O'Reilly Media, Inc. (2024)
  Concepto clave: Madurez en ingeniería de sistemas de IA mediante distribución eficiente de cargas de trabajo; patrones de enrutamiento (*routing*), cascadas de modelos y gestión de presupuestos de latencia y coste. Citada en el **Módulo 3.3**.
- **Generative AI Design Patterns**
  Autores: Valliappa Lakshmanan y Hannes Hapke · **Editorial:** O'Reilly Media, Inc. (2025)
  Concepto clave: Patrones formales de *Semantic Routing*, *Confidence Gate* (Puerta de Confianza) y evaluadores en cascada para canalizaciones corporativas. Citada en los **Módulos 2.4 y 3.3**.
- **Building Applications with AI Agents**
  Autor: Michael Albada · **Editorial:** O'Reilly Media, Inc. (2025)
  Concepto clave: Desacople del bucle de decisión de baja latencia del agente respecto a la síntesis generativa; viabilidad y rendimiento de grafos de ejecución en sistemas compuestos. Citada en los **Módulos 2.3 y 2.4**.
- **Designing Large Language Model Applications**
  Autor: Suhas Pai · **Editorial:** O'Reilly Media, Inc. (2025)
  Concepto clave: Descalibración probabilística y sobreconfianza patológica inducidas por el entrenamiento RLHF frente a los requisitos de calibración epistémica. Citada en el **Módulo 3.1**.
- **Neuro-Symbolic AI**
  Autores: Alexiei Dingli y David Farrugia · **Editorial:** Packt / O'Reilly (2023)
  Concepto clave: Integración de la percepción conexionista (Sistema 1) con lógica simbólica y reglas formales de software (Sistema 2). Citada en el **Módulo 4.1**.

1.2. Inferencia, Optimización de Hardware y Servicio de Modelos

- **Hands-On LLM Serving and Optimization**
  Autores: Chi Wang y Peiheng Hu · **Editorial:** O'Reilly Media, Inc. (2026)

Concepto clave: Restricciones físicas de la decodificación autorregresiva token a token (*memory--bound bottleneck* por la caché KV) frente a la computación densa en una sola pasada (*Parallel Sampler*). Citada en el **Módulo 3.1**.

- **Prompt Engineering for LLMs**
  Autores: John Berryman y Albert Ziegler · **Editorial:** O'Reilly Media, Inc. (2024)
  Concepto clave: Fragilidad operacional, bloqueos (*deadlocks*) y sobrecostes de forzar esquemas JSON y gramáticas formales sobre modelos autorregresivos. Citada en el **Módulo 3.1**.
- **Hands-On Large Language Models**
  Autores: Jay Alammar y Maarten Grootendorst · **Editorial:** O'Reilly Media, Inc. (2024)
  Concepto clave: Representaciones internas densas en transformadores, cabezales de decisión tipada frente a cabezales de generación textual abierta. Citada en los **Módulos 2.2 y 3.1**.

1.3. Ingeniería de Software Distribuido y Sistemas de Datos

- **Software Engineering at Google**
  Autores: Titus Winters, Tom Manshreck y Hyrum Wright · **Editorial:** O'Reilly Media, Inc. (2020)
  Concepto clave: Presupuestos de latencia en sistemas distribuidos a gran escala; cambio cualitativo cuando una operación cruza el umbral de los 100 ms y se transforma en una primitiva síncrona componible en línea. Citada en el **Módulo 3.2**.
- **Designing Data-Intensive Applications, 2nd Edition**
  Autores: Martin Kleppmann y Chris Riccomini · **Editorial:** O'Reilly Media, Inc. (2026)
  Concepto clave: Principio de estratificación y aislamiento de fallos; descomposición de sistemas complejos en primitivas atómicas fiables, verificables y auditables. Citada en los **Módulos 2.3 y 2.4**.
- **Artificial Integrity**
  Autor: Hamilton Mann · **Editorial:** Wiley / O'Reilly (2024)
  Concepto clave: Aplicación de la Paradoja de Jevons al despliegue masivo de algoritmos de decisión en procesos operativos corporativos. Citada en el **Módulo 3.2**.
- **Reinforcement Learning from Human Feedback**
  Autor: Nathan Lambert · **Editorial:** Manning / O'Reilly (2026)
  Concepto clave: Modelos de recompensa (*reward models*), optimización por preferencia humana y divergencia respecto a la calibración de probabilidades reales. Citada en los **Módulos 1.3, 2.1 y 4.2**.
- **Uncertainty in Artificial Intelligence**
  Autores: Bruce D'Ambrosio, Philippe Smets y Piero Bonissone · **Editorial:** Morgan Kaufmann / O'Reilly
  Concepto clave: Teoría de decisión bayesiana, cuantificación formal de incertidumbre aleatoria y epistémica, y funciones de pérdida bajo riesgo. Citada en el **Módulo 4.3**.
- **The DeepSeek Moment: A New Era of Efficiency, Intelligent Design, and Democratization**
  Autores: Harshad Oak y Monish Darda · **Editorial:** Apress / O'Reilly (2026)
  Concepto clave: Dinámica industrial en la que una disrupción radical en eficiencia fuerza la adopción universal de un nuevo estándar técnico por parte de todas las grandes tecnológicas. Citada en el **Módulo 5.0**.

2. Investigaciones Fundacionales y Artículos de Pioneros

- ***The Bitter Lesson* (2019) y *The Bitterest Lesson* (2026)**
  Autores: Richard Sutton (2019) · Diogo Almeida (TypeSafe AI, 2026)
  Aporte: Formulación de la ley del cómputo general en aprendizaje automático, extendida por Almeida hacia la necesidad de superar la interfaz conversacional de texto para software.
- ***The Shift from Models to Compound AI Systems* (2024)**
  Autores: Matei Zaharia, Omar Khattab, Lingjiao Chen et al. (BAIR, UC Berkeley / Databricks)
  Aporte: Demostración de que el estado del arte en fiabilidad y coste se alcanza orquestando sistemas compuestos con grafos de código, no aumentando el tamaño del modelo monolítico.
- ***Training language models to follow instructions with human feedback* [InstructGPT] (2022)**
  Autores: Long Ouyang, Jeff Wu, Xu Chen, Diogo Almeida et al. (OpenAI)
  Aporte: Introducción fundacional de la alineación conversacional mediante RLHF y origen de la segunda ola de la IA generativa.
- ***Language Models are Few-Shot Learners* [GPT-3] (2020)**
  Autores: Tom Brown, Benjamin Mann, Nick Ryder et al. (OpenAI)
  Aporte: Consolidación del paradigma del simulador de siguiente token y despegue de la computación basada en modelos de lenguaje masivos.
- ***From System 1 Deep Learning to System 2 Deep Learning* (NeurIPS 2019)**
  Autor: Yoshua Bengio (Premio Turing)
  Aporte: Exposición de los límites del aprendizaje profundo perceptivo y la necesidad de acoplarlo a arquitecturas con capacidades de deliberación y composición.

3. Obras Clásicas de Economía, Ciencias Cognitivas y Neurofisiología

- ***The Coal Question* (1865)**
  Autor: William Stanley Jevons
  Aporte: Formulación original de la Paradoja de Jevons: el incremento drástico de eficiencia en un recurso energético multiplica exponencialmente su consumo agregado total al colonizar nuevas industrias.
- ***Thinking, Fast and Slow* (2011)**
  Autor: Daniel Kahneman (Premio Nobel de Economía)
  Aporte: Taxonomía dual de procesos cognitivos: Sistema 1 (inmediato, asociativo, intuitivo y de bajo coste energético) y Sistema 2 (deliberativo, secuencial, analítico y lento).
- ***The Integrative Action of the Nervous System* (1906)**
  Autor: Sir Charles Scott Sherrington (Premio Nobel de Medicina)
  Aporte: Descripción del arco reflejo periférico: procesamiento sensoriomotor local e instantáneo que descarga al córtex cerebral de las reacciones primarias de supervivencia.
- ***Understanding Media: The Extensions of Man* (1964)**
  Autor: Marshall McLuhan
  Aporte: Concepto del «espejo retrovisor»: tendencia histórica a encorsetar una tecnología disruptiva dentro de los formatos y metáforas de la tecnología a la que reemplaza.
- ***Verification of Forecasts Expressed in Terms of Probability* [Brier Score] (1950)**
  Autor: Glenn W. Brier
  Aporte: Regla de puntuación estrictamente propia (Brier Score) y descomposición matemática del error en fiabilidad, resolución e incertidumbre.

4. Matriz de Trazabilidad por Módulo y Diapositiva

Módulo	Autores Citados	Obra o Concepto Fundamental
1.1	Diogo Almeida, Richard Sutton	*The Bitter Lesson* vs. *The Bitterest Lesson*
1.2	Marshall McLuhan, James Watt	El carruaje sin caballos y la metáfora del retrovisor
1.3	Daniel Kahneman, Nathan Lambert	Sistema 1 vs. Sistema 2 y calibración probabilística RLCD
2.1	Tom Brown, Diogo Almeida	De la predicción de tokens a InstructGPT y RLHF
2.2	Charles Sherrington, Jay Alammar	El arco reflejo periférico frente al córtex deliberativo
2.3	Martin Kleppmann, Michael Albada	Aislamiento de capas, fiabilidad y componibilidad
2.4	Matei Zaharia, Michael Albada	*Compound AI Systems* y grafos de flujo en código
3.1	Chi Wang, John Berryman, Suhas Pai	Límites del KV Cache, fragilidad JSON y sobreconfianza
3.2	W. S. Jevons, Winters & Wright, H. Mann	Paradoja de Jevons, latencia síncrona y consumo en BBDD
3.3	Chip Huyen, Lakshmanan & Hapke	Adecuación de modelos y patrón *Confidence Gate*
4.1	Daniel Kahneman, Yoshua Bengio, Dingli & Farrugia	Procesamiento dual cognitivo y arquitectura neuro-simbólica
4.2	Nathan Lambert, Suhas Pai, Glenn W. Brier	Modelo Bradley-Terry, sobreconfianza RLHF, ECE y Brier Score
4.3	Bruce D'Ambrosio, Chip Huyen	Teoría de decisión, incertidumbre y políticas de abstención
4.4	Dingli & Farrugia, Lakshmanan & Hapke, M. Albada	Síntesis neuro-simbólica y patrones de sistemas compuestos
5.0	Harshad Oak, Monish Darda, Chip Huyen	Efecto DeepSeek, comoditización del System One y RouteLLM
5.1	Chip Huyen, Michael Albada, Jay Alammar, John Berryman	Interfaces tipadas, primitivas Choice, Score, Noul y muestreo O(1)
5.2	Chip Huyen, Dr. Ali Arsanjani, Chi Wang, Mark Richards	Fast Router, enrutamiento síncrono en Gateway y ahorro del 91%
5.3	Lakshmanan & Hapke, Chip Huyen, M. Albada	Patrón Confidence Gate (p >= 0.85), triage dual y ahorro del 82%
5.4	Vaibhav Malik, Sampriti Mitra, Suhas Pai	Realtime Guardrails, cortafuegos síncrono en Ingress y defensa TTFT

5.5	Michael Albada, John Berryman, Dr. Ali Arsanjani, S. Mitra	Deterministic Tool Dispatch, invocación tipada en 71 ms y puerta 2FA
5.6	Chi Wang, Ammar Mohanna, Titus Winters, Sampriti Mitra	Benchmark Cuantitativo (1.000 reqs), percentiles P50/P99 y SLA < 100 ms
6.1	Chip Huyen, Lakshmanan, M. Albada, N. Lambert, M. Kleppmann	Síntesis ejecutiva del curso, arquitectura unificada y hoja de ruta en 4 fases